

Implementación de un Chatbot para la Recuperación de Artículos Científicos mediante Generación Aumentada por Recuperación (RAG)

Jennifer de la Caridad Sánchez Santana¹ and Reinaldo Cánvas Gamón²

Facultad de Ciencia de Datos, Universidad de La Habana
La Habana, Cuba

Índice

Implementación de un Chatbot para la Recuperación de Artículos Científicos mediante Generación Aumentada por Recuperación (RAG) . . .	1
<i>Jennifer de la Caridad Sánchez Santana and Reinaldo Cánvas Gamón</i>	
1. Introducción	2
2. Estado del Arte	3
3. Desarrollo	3
3.1. Extracción de Artículos	4
3.2. Almacenamiento en Repositorio Vectorial	4
3.3. Implementación del Chatbot	4
4. Consideraciones tomadas a la hora de implementar el RAG	5
5. Análisis Crítico de la Implementación	6
5.1. Logros Principales	6
5.2. Limitaciones Identificadas	7
6. Conclusiones	7
7. Recomendaciones	7

Resumen Este artículo presenta el desarrollo de un sistema de recuperación y recomendación de artículos científicos, basado en el modelo de Generación Aumentada por Recuperación (RAG). El objetivo es construir un chatbot capaz de responder preguntas en lenguaje natural utilizando artículos previamente recopilados y procesados, mejorando el acceso a la información académica relevante mediante técnicas de embeddings y búsqueda semántica.

Palabras clave: Recuperación de Información, RAG, chatbot, embeddings, artículos científicos

1. Introducción

En el ámbito de la investigación científica, mantenerse actualizado sobre los últimos descubrimientos es esencial. Sin embargo, el volumen de publicaciones científicas crece exponencialmente, lo que representa tanto una oportunidad como un desafío para investigadores, estudiantes y profesionales. La búsqueda eficiente de información relevante y el acceso a los documentos completos suelen ser tareas complejas.

Con el objetivo de facilitar el acceso a conocimiento científico, se propone el desarrollo de un chatbot que simule una conversación natural con el usuario, permitiéndole recuperar información especializada mediante una interfaz interactiva. Este sistema combina técnicas modernas de procesamiento de lenguaje natural, embeddings semánticos y recuperación de información basada en

similitud. El código fuente del proyecto está disponible en el repositorio de GitHub: <https://github.com/Jennyfer2004/SRI-Investigaci-n-cient-fica>.

2. Estado del Arte

La recuperación de información científica ha sido tradicionalmente abordada mediante motores de búsqueda basados en coincidencia de palabras clave. Sin embargo, estos sistemas presentan limitaciones al interpretar consultas en lenguaje natural o al identificar documentos relevantes en contextos semánticos complejos. En respuesta a estas limitaciones, se han desarrollado sistemas conversacionales que integran técnicas de Procesamiento de Lenguaje Natural (PLN) y aprendizaje profundo para mejorar la interacción con el usuario y la precisión de los resultados.

Los chatbots han evolucionado desde sistemas basados en reglas hacia modelos generativos que emplean redes neuronales profundas. En particular, los Modelos de Lenguaje de Gran Tamaño (LLMs) como GPT, BERT y Zephyr han demostrado capacidades avanzadas en tareas de comprensión y generación de texto. No obstante, estos modelos enfrentan desafíos como la obsolescencia del conocimiento y la generación de respuestas incorrectas o alucinadas.

Para mitigar estas limitaciones, surge el enfoque de **Generación Aumentada por Recuperación (RAG)**, propuesto inicialmente por Meta AI en 2020. RAG combina un módulo de recuperación semántica con un modelo generativo, permitiendo que el sistema acceda a fuentes externas actualizadas durante el proceso de generación. Esta arquitectura mejora la precisión actual y la relevancia contextual de las respuestas.

El RAG ha sido aplicado en varios dominios, en el ámbito académico, su uso permite construir asistentes conversacionales capaces de responder preguntas complejas utilizando artículos científicos como fuente primaria. Además, herramientas como LangChain y bases vectoriales como Chroma han facilitado la implementación de sistemas RAG personalizados, adaptables a colecciones documentales específicas.

Este trabajo se enmarca en dicha línea de investigación, proponiendo un chatbot que emplea RAG para recuperar y sintetizar información científica, contribuyendo al acceso eficiente y contextualizado al conocimiento académico.

3. Desarrollo

La arquitectura del sistema propuesto se compone de varios módulos interconectados que permiten la recopilación, procesamiento y recuperación de información científica. El flujo inicia con la recolección de artículos académicos mediante APIs públicas, seguido por un proceso de preprocesamiento que limpia, estructura y vectoriza los datos, luego vectores semánticos mediante modelos de generación de embeddings, lo que permite realizar búsquedas por similitud en un repositorio optimizado para este tipo de consultas.

3.1. Extracción de Artículos

Para alimentar el sistema con información científica, se extrajeron aproximadamente 2000 artículos relacionados con unos 100 temas de interés. Las consultas se realizaron utilizando la API de Crossref (<https://api.crossref.org/works>), que devuelve metadatos como el autor, la fecha de publicación, el DOI, entre otros. Posteriormente, se empleó la API de Unpaywall (<https://api.unpaywall.org/v2/{doi}>) para recuperar la URL del artículo completo, en los casos en que esté disponible gratuitamente. Los artículos con acceso abierto se procesaron para extraer tanto sus metadatos como su contenido textual. Inicialmente, los datos se almacenaron en un archivo CSV por razones de conectividad.

Extracción de Referencias Una vez recopilados los artículos, se analizaron sus contenidos en busca de referencias a otros trabajos mediante expresiones regulares. A partir de los DOIs identificados, se consultó nuevamente la API de Crossref para obtener los metadatos correspondientes y enriquecer la colección.

3.2. Almacenamiento en Repositorio Vectorial

Preprocesamiento Los documentos se depuraron para eliminar aquellos con contenido o metadatos faltantes. Se unificaron los artículos originales y las referencias, y se procesaron campos como el contenido y el resumen. Se eliminaron caracteres especiales, espacios innecesarios, secciones irrelevantes como las referencias, y artículos con menos de 200 palabras.

Generación de Embeddings Cada artículo se dividió en dos componentes: texto (contenido + resumen) y metadatos (autor, idioma, fecha, URL, etc.). El texto se fragmentó en bloques de unas 1200 palabras con una superposición de 200, generando aproximadamente 91 717 fragmentos. Estos fueron procesados mediante el modelo `sentence-transformers/all-MiniLM-L6-v2`, seleccionado por su eficiencia, bajo consumo de recursos y buen rendimiento en tareas de búsqueda semántica.

Los vectores resultantes, junto con los metadatos, fueron almacenados en la base de datos vectorial Chroma, una solución open-source optimizada para búsquedas basadas en embeddings y filtrado por metadatos.

3.3. Implementación del Chatbot

Interfaz Visual La interfaz, desarrollada con Streamlit, presenta el título “Chatbot RAG de Investigación Científica”. En la parte superior se sugieren preguntas al usuario, mientras que en la parte inferior se permite ingresar consultas personalizadas. Al seleccionar una pregunta, se muestra la respuesta generada, los artículos utilizados como referencia y recomendaciones adicionales basadas en el historial de interacciones.

Lógica Backend El backend, implementado con FastAPI, se conecta al repositorio vectorial para recuperar documentos relevantes según la similitud coseno con la consulta del usuario. Si el puntaje de similitud es inferior a 0.25 o los documentos están desactualizados (más de cinco años), se realiza una búsqueda en tiempo real similar a la fase de recolección inicial.

Las respuestas generadas provienen del modelo `HuggingFaceH4/zephyr-7b-beta`, accedido vía API en <https://api-inference.huggingface.co/models/HuggingFaceH4/zephyr-7b-beta>. Este modelo fue elegido por su balance entre tamaño, eficiencia y calidad de respuesta en inglés.

Para generar recomendaciones, se analiza el historial de consultas almacenado en un archivo JSON. Se filtran las palabras vacías (stop words) y se extraen los trigramas más representativos mediante la métrica TF-IDF.

4. Consideraciones tomadas a la hora de implementar el RAG

Aunque nuestro sistema se basa en el enfoque estándar de Generación Aumentada por Recuperación (RAG), se han incorporado consideraciones técnicas y funcionales que lo distinguen de un sistema RAG tradicional, mejorando su utilidad, precisión y accesibilidad en el contexto académico.

1. **Gestión dinámica de documentos desactualizados:** En lugar de usar únicamente documentos fijos previamente indexados, nuestro sistema verifica si los documentos utilizados para generar una respuesta tienen más de cinco años. Si es así, realiza una búsqueda en tiempo real utilizando APIs como Crossref y Unpaywall para obtener información actualizada. Esto evita que el chatbot ofrezca respuestas obsoletas.
2. **Traducción automática bidireccional:** A diferencia de muchos sistemas RAG enfocados en inglés, nuestro chatbot permite al usuario interactuar en español. Las consultas son traducidas automáticamente al inglés antes de ser procesadas por el LLM (`Zephyr-7B-beta`), y las respuestas son devueltas traducidas al español. Esta funcionalidad amplía significativamente su alcance a usuarios que hablen el idioma español.
3. **Recomendación contextual de nuevos artículos:** Además de responder preguntas, nuestro sistema ofrece recomendaciones personalizadas basadas en el historial de consultas del usuario. Para ello, se utiliza TF-IDF sobre trigramas extraídos del historial, permitiendo sugerir artículos relacionados con los intereses recientes del usuario.
4. **Fragmentación inteligente de documentos:** Para mejorar la calidad de la recuperación semántica, cada artículo no se ingresa completo, sino fragmentado en bloques de 1200 palabras con una superposición de 200. Este enfoque asegura que se capturen relaciones contextuales complejas sin perder coherencia temática, algo que muchos sistemas RAG ignoran al trabajar con documentos completos o fragmentos demasiado pequeños.

5. **Uso de embeddings eficientes y localizados:** Se ha seleccionado el modelo `sentence-transformers/all-MiniLM-L6-v2` por su equilibrio entre rendimiento y consumo de recursos. Además, se almacenan los embeddings localmente en Chroma DB, permitiendo búsquedas rápidas y escalables sin depender exclusivamente de servicios externos de embeddings.
6. **Interfaz interactiva y amigable:** La interfaz gráfica desarrollada con Streamlit permite no solo realizar consultas, sino también explorar las referencias usadas por el sistema y recibir recomendaciones personalizadas.
7. **Almacenamiento y filtrado por metadatos:** El uso de Chroma DB no solo permite almacenar vectores semánticos, sino también asociarlos a metadatos como autor, año, idioma y DOI. Esto posibilita realizar búsquedas filtradas por criterios adicionales.

5. Análisis Crítico de la Implementación

Este apartado ofrece una evaluación autocrítica sobre los aspectos técnicos y funcionales del sistema propuesto, destacando sus fortalezas y sus debilidades en el contexto de la recuperación de información científica. Se revisa el desempeño general del chatbot desde una perspectiva práctica, considerando tanto la calidad de las respuestas como la experiencia del usuario final.

5.1. Logros Principales

El desarrollo del chatbot RAG para recuperación científica ha demostrado varios avances significativos:

- **Integración exitosa de tecnologías emergentes:** Se logró combinar efectivamente modelos de embeddings (`all-MiniLM-L6-v2`), bases vectoriales (Chroma) y LLMs (Zephyr-7B-beta) en un flujo de trabajo coherente, superando los desafíos de compatibilidad entre componentes.
- **Procesamiento a escala:** El sistema maneja satisfactoriamente un corpus de 2,000 artículos científicos, transformándolos en 91,717 fragmentos semánticos con metadatos asociados, demostrando capacidad para gestionar volúmenes considerables de literatura académica.
- **Resultados en Español:** Las respuestas generadas por el LLM, aunque originalmente eran en inglés, así como la mayoría de los artículos, son traducidas de manera automática tanto la consulta enviada al LLM como la respuesta final al idioma Español.
- **Facilidad de uso:** La interfaz creada con Streamlit es simple y fácil de manejar, ideal para investigadores sin conocimientos técnicos, haciendo más accesible la información científica.
- **Actualización dinámica:** La arquitectura permite incorporar nuevos artículos sin requerir reentrenamiento del modelo completo, manteniendo la relevancia temporal de los resultados.

5.2. Limitaciones Identificadas

Sin embargo, la implementación actual presenta varias áreas que requieren mejora:

- **Consultas limitada:** La dependencia del modelo Zephyr-7B (el cual está optimizado para inglés) tiene un limitado plan de consultas gratuitas .
- **Dependencia del idioma inglés:** Aunque la interfaz admite consultas en español, el sistema traduce automáticamente las preguntas al inglés antes de enviarlas al modelo Zephyr-7B, lo que puede introducir imprecisiones en la interpretación.
- **Latencia por traducción externa:** El proceso de traducción utiliza la biblioteca `deep_translator`, basada en Google Translate, lo que requiere una conexión a internet estable. Esta dependencia puede provocar latencia en las respuestas.
- **Sesgo en fuentes de datos:** La dependencia exclusiva de Crossref y Unpaywall introduce posibles sesgos hacia ciertas editoriales o instituciones, afectando la diversidad epistemológica de los resultados.
- **Problemas de actualización:** El umbral fijo de 5 años para considerar documentos "desactualizados" no se adapta a las diferentes velocidades de obsolescencia entre disciplinas científicas.

Este análisis autocrítico subraya que, si bien el sistema representa un avance significativo en acceso a literatura científica, su valor real dependerá de la capacidad para abordar estas limitaciones en iteraciones futuras.

6. Conclusiones

Este trabajo presenta una solución práctica al problema de acceso a información científica mediante un chatbot que combina técnicas de recuperación semántica y generación de lenguaje. El sistema permite obtener respuestas sintetizadas y referencias relevantes, facilitando la exploración de conocimiento en diversos dominios.

7. Recomendaciones

Tras la implementación y prueba del sistema, se identificaron varias oportunidades de mejora que pueden aumentar su rendimiento y utilidad para el usuario final. A continuación, se proponen algunas recomendaciones con el fin de optimizar el funcionamiento del chatbot y ampliar su cobertura científica:

- Aumentar la cantidad de artículos en el repositorio vectorial.
- Ampliar la cuota de consultas disponibles para el modelo `HuggingFaceH4/zephyr-7b-beta`.
- Desplegar el repositorio y el chatbot en servidores en línea para mayor accesibilidad.
- Incluir documentos en otros idiomas, especialmente en español, para diversificar las fuentes.

Referencias

1. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding <https://arxiv.org/pdf/1810.04805>, last accessed 2018/10/11.
2. Retrieval-Augmented Generation (RAG) <https://link.springer.com/content/pdf/10.1007/s12599-025-00945-3.pdf>, last accessed 2025/6/1.
3. Check for URL in a String - Python, https://www.geeksforgeeks-org.translate.google/python/python-check-url-string/?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=rq, last accessed 2025/4/12.
4. Top embedding models for RAG, https://modal-com.translate.google/blog/embedding-models-article?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc, last accessed 2024/10/30.
5. ¿QUÉ ES EL DOI?, <https://3ciencias.com/que-es-el-doi/>, last accessed 2021/5/3.
6. sentence-transformers/all-MiniLM-L6-v2 , https://huggingface-co.translate.google/sentence-transformers/all-MiniLM-L6-v2?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc, last accessed 2024/6/18.
7. Tutorial de la base de datos vectorial Chroma, <https://anderfernandez.com/blog/chroma-vector-database-tutorial/>, last accessed 2023/6.
8. Chroma is the open-source AI application database. Batteries included, <https://www.trychroma.com/>, last accessed 2025.
9. Exploring Vector Databases: A Guide to Their Role in AI Tech, https://www-projectpro-io.translate.google/article/vector-databases/903?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc, last accessed 2024/10/28.
10. Model Card for Zephyr 7B Beta. Disponible en: <https://huggingface.co/HuggingFaceH4/zephyr-7b-beta>.
11. Language Models are Few-Shot Learners <https://arxiv.org/pdf/2005.14165>, last accessed 2020/7/22.
12. UNAM Global. “Me lo dijo ChatGPT”: análisis de riesgos y usos de los chatbots en la ciencia. Disponible en: https://unamglobal.unam.mx/global_revista/me-lo-dijo-chatgpt/, last accessed 2025/6/12.
13. Oracle América Latina. ¿Qué es la generación con recuperación aumentada (RAG)? Disponible en: <https://www.oracle.com/latam/artificial-intelligence/generative-ai/retrieval-augmented-generation-rag/>, last accessed 2025/6/10.
14. IAMAI. ¿Qué es la Generación Aumentada de Recuperación (RAG)? Disponible en: <https://iamai.es/Blog/Qu%C3%A9-es-la-generaci%C3%B3n-aumentada-de-recuperaci%C3%B3n-RAG/>, last accessed 2025/6/10.